

VARモデル

1 ラグオペレーター

表記を簡単にするために、ラグオペレーターという演算子を導入する。

$$L(y_t) = y_{t-1} \quad L^k(y_t) = y_{t-k}$$

2 n変数VAR(p)

$$y_t = W^T \Phi(y_t) + \epsilon_t \quad \epsilon_t \sim W.N.(\Sigma)$$

$$y_t = \begin{bmatrix} y_{1t} \\ y_{2t} \\ \vdots \\ y_{nt} \end{bmatrix} \quad W = \begin{bmatrix} w_{11} & w_{12} & \cdots & w_{1n} \\ w_{21} & w_{22} & \cdots & w_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ w_{np+1,1} & w_{np+1,2} & \cdots & w_{np+1,n} \end{bmatrix} \quad \Phi(y_t) = \begin{bmatrix} \Phi_0(y_t) \\ \Phi_1(y_t) \\ \vdots \\ \Phi_{np+1}(y_t) \end{bmatrix}$$

基底関数 $\Phi(y_t)$ は $\Phi_j(y_t)$ が第 j 成分の $np+1 \times 1$ の列ベクトルである。各成分はラグオペレーターを用いて次のように定義される。

$$\Phi_0(y_t) = 1$$

$$\Phi_j(y_t) = \begin{cases} L(y_{jt}) & j = 1, 2, \dots, n \\ L^2(y_{j-n,t}) & j = n+1, n+2, \dots, 2n \\ \vdots \\ L^p(y_{j-n(p-1),t}) & j = n(p-1)+1, n(p-1)+2, \dots, np \end{cases}$$

3 2変量VAR(2)

$$\begin{aligned} \begin{bmatrix} y_{1t} \\ y_{2t} \end{bmatrix} &= \begin{bmatrix} w_{11} & w_{12} \\ w_{21} & w_{22} \\ w_{31} & w_{32} \\ w_{41} & w_{42} \\ w_{51} & w_{52} \end{bmatrix}^T \begin{bmatrix} 1 \\ \Phi_1(y_t) \\ \Phi_2(y_t) \\ \Phi_3(y_t) \\ \Phi_4(y_t) \end{bmatrix} + \begin{bmatrix} \epsilon_1 \\ \epsilon_2 \end{bmatrix} \\ &= \begin{bmatrix} w_{11} + w_{21}\Phi_1(y_t) + w_{31}\Phi_2(y_t) + w_{41}\Phi_3(y_t) + w_{51}\Phi_4(y_t) \\ w_{12} + w_{22}\Phi_1(y_t) + w_{32}\Phi_2(y_t) + w_{42}\Phi_3(y_t) + w_{52}\Phi_4(y_t) \end{bmatrix} + \begin{bmatrix} \epsilon_1 \\ \epsilon_2 \end{bmatrix} \\ &= \begin{bmatrix} w_{11} + w_{21}y_{1,t-1} + w_{31}y_{2,t-1} + w_{41}y_{1,t-2} + w_{51}y_{2,t-2} \\ w_{12} + w_{22}y_{1,t-1} + w_{32}y_{2,t-1} + w_{42}y_{1,t-2} + w_{52}y_{2,t-2} \end{bmatrix} + \begin{bmatrix} \epsilon_1 \\ \epsilon_2 \end{bmatrix} \end{aligned}$$

4 n変量VAR(p)の最尤推定

VAR(p) が時刻tの状態、 y_t が得られる確率は

$$\begin{aligned} y_t &= W^T \Phi(y_t) + \epsilon_t \quad \epsilon_t \sim W. N.(\Sigma) \\ \Rightarrow \epsilon_t &= W^T \Phi(y_t) + y_t \\ \Rightarrow P(y_t | y_{t-p}, y_{t-p+1}, \dots, y_{t-2}, y_{t-1}; \theta) &= \frac{1}{\sqrt{(2\pi)^N \det \Sigma}} \exp \left\{ -\frac{1}{2} (y_t - W^T \Phi(y_t))^T \Sigma^{-1} (y_t - W^T \Phi(y_t)) \right\} \end{aligned}$$

θ はパラメータをまとめたものである。ここでこれまでのデータ、 y_1, y_2, \dots, y_{t-1} が得られる確率は

$$\begin{aligned} &P(y_{p+1}, y_{p+2}, \dots, y_{t-2}, y_{t-1} | y_1, y_2, \dots, y_{p-1}, y_p; \theta) \\ &= P(y_{p+1} | y_1, y_2, \dots, y_{p-1}, y_p; \theta) \times P(y_{p+2} | y_2, y_3, \dots, y_p, y_{p+1}; \theta) \times \dots \\ &\quad \dots \times P(y_{t-1} | y_{t-p-1}, y_{t-p}, \dots, y_{t-3}, y_{t-2}; \theta) \\ &= \frac{1}{\sqrt{(2\pi)^N \det \Sigma}} \exp \left\{ -\frac{1}{2} (y_{p+1} - W^T \Phi(y_{p+1}))^T \Sigma^{-1} (y_{p+1} - W^T \Phi(y_{p+1})) \right\} \times \\ &\quad \times \frac{1}{\sqrt{(2\pi)^N \det \Sigma}} \exp \left\{ -\frac{1}{2} (y_{p+2} - W^T \Phi(y_{p+2}))^T \Sigma^{-1} (y_{p+2} - W^T \Phi(y_{p+2})) \right\} \times \dots \\ &\quad \dots \times \frac{1}{\sqrt{(2\pi)^N \det \Sigma}} \exp \left\{ -\frac{1}{2} (y_{t-1} - W^T \Phi(y_{t-1}))^T \Sigma^{-1} (y_{t-1} - W^T \Phi(y_{t-1})) \right\} \\ &= \left(\frac{1}{\sqrt{(2\pi)^N \det \Sigma}} \right)^{t-p-1} \exp \left\{ -\frac{1}{2} \sum_{k=1}^{t-p-1} (y_{p+k} - W^T \Phi(y_{p+k}))^T \Sigma^{-1} (y_{p+k} - W^T \Phi(y_{p+k})) \right\} \end{aligned}$$

となる。

最大化すべきパラメータ θ の関数は

$$\begin{aligned} L(\theta) &= \ln P(y_{p+1}, y_{p+2}, \dots, y_{t-2}, y_{t-1} | y_1, y_2, \dots, y_{p-1}, y_p; \theta) \\ &= -\frac{N(t-p-1)}{2} \ln(2\pi) - \frac{t-p-1}{2} \ln(\det \Sigma) \\ &\quad - \frac{1}{2} \sum_{k=1}^{t-p-1} (y_{p+k} - W^T \Phi(y_{p+k}))^T \Sigma^{-1} (y_{p+k} - W^T \Phi(y_{p+k})) \end{aligned}$$

4.1 wについて微分

$L(\theta)$ のwに関する項は

$$\begin{aligned}
&\Rightarrow -\frac{1}{2} \sum_{k=1}^{t-p-1} (y_{p+k} - W^T \Phi(y_{p+k}))^T \Sigma^{-1} (y_{p+k} - W^T \Phi(y_{p+k})) \\
&= -\frac{1}{2} \sum_{k=1}^{t-p-1} \left\{ y_{p+k}^T \Sigma^{-1} y_{p+k} - y_{p+k}^T \Sigma^{-1} W^T \Phi(y_{p+k}) \right. \\
&\quad \left. - (W^T \Phi(y_{p+k}))^T \Sigma^{-1} y_{p+k} + (W^T \Phi(y_{p+k}))^T \Sigma^{-1} W^T \Phi(y_{p+k}) \right\}
\end{aligned}$$

となる。ここで第一項は w を含まないので、微分すると消える。また、共分散行列である Σ は対称行列であるので、 Σ^{-1} もまた対称行列である。これを利用すると、第二項と第三項は等しいということがわかる。これにより実際に微分に関わる項は次のようになる。

$$\Rightarrow -\frac{1}{2} \sum_{k=1}^{t-p-1} \left(-2y_{p+k}^T \Sigma^{-1} W^T \Phi(y_{p+k}) + (W^T \Phi(y_{p+k}))^T \Sigma^{-1} W^T \Phi(y_{p+k}) \right)$$

この式を、6. 行列の微分の式(*) (**)を利用して解くと

$$\begin{aligned}
\frac{\partial}{\partial W} &= -\frac{1}{2} \sum_{k=1}^{t-p-1} (-2\Phi(y_{p+k})y_{p+k}^T \Sigma^{-1} + \Phi(y_{p+k})\Phi(y_{p+k})^T W \Sigma^{-1}) \\
\frac{\partial}{\partial W} &= 0より
\end{aligned}$$

$$\sum_{k=1}^{t-p-1} \Phi(y_{p+k})y_{p+k}^T \Sigma^{-1} = \sum_{k=1}^{t-p-1} \Phi(y_{p+k})\Phi(y_{p+k})^T W \Sigma^{-1}$$

両辺に右から Σ をかけて

$$\sum_{k=1}^{t-p-1} \Phi(y_{p+k})y_{p+k}^T = \sum_{k=1}^{t-p-1} \Phi(y_{p+k})\Phi(y_{p+k})^T W$$

ここで、 Ψ 、 Y を次のように定める。

$$\Psi = \begin{bmatrix} \Phi_0(y_{p+1}) & \Phi_1(y_{p+1}) & \cdots & \Phi_{np}(y_{p+1}) \\ \Phi_0(y_{p+2}) & \Phi_1(y_{p+2}) & \cdots & \Phi_{np}(y_{p+2}) \\ \vdots & \vdots & \ddots & \vdots \\ \Phi_0(y_{t-1}) & \Phi_1(y_{t-1}) & \cdots & \Phi_{np}(y_{t-1}) \end{bmatrix} \quad Y = \begin{bmatrix} y_{p+1}^T \\ y_{p+2}^T \\ \vdots \\ y_{t-1}^T \end{bmatrix}$$

$$\begin{aligned}
&\Rightarrow \Psi^T Y = \Psi^T \Psi W \\
W_{ML} &= (\Psi^T \Psi)^{-1} \Psi^T Y
\end{aligned}$$

4.2 Σ について微分

行列の公式を用いると、パラメータ θ の関数の指数部分がトレースで書き換えることができる。

$$\begin{aligned}
L(\theta) &= -\frac{N(t-p-1)}{2} \ln(2\pi) + \frac{t-p-1}{2} \ln(\det \Sigma^{-1}) \\
&\quad - \frac{1}{2} \sum_{k=1}^{t-p-1} \text{Tr} \left\{ \Sigma^{-1} (y_{p+k} - W^T \Phi(y_{p+k})) (y_{p+k} - W^T \Phi(y_{p+k}))^T \right\}
\end{aligned}$$

ここで、 Σ の (i, j) 成分を σ_{ij} 、 Σ^{-1} の (i, j) 成分を λ_{ij} とすると

$$\begin{aligned}\frac{\partial L(\theta)}{\partial \sigma_{ij}} &= \frac{\partial L(\theta)}{\partial \lambda_{ij}} \times \frac{\partial \lambda_{ij}}{\partial \sigma_{ij}} \\ &= -\frac{1}{2} \left\{ \sum_{k=1}^{t-p-1} \frac{\partial}{\partial \lambda_{ij}} \text{Tr} \left\{ \Sigma^{-1} (y_{p+k} - W^T \Phi(y_{p+k})) (y_{p+k} - W^T \Phi(y_{p+k}))^T \right\} \right. \\ &\quad \left. - (t-p-1) \frac{\partial}{\partial \lambda_{ij}} \ln(\det \Sigma^{-1}) \right\} \times \frac{\partial \lambda_{ij}}{\partial \sigma_{ij}} \\ &= -\frac{1}{2} \left\{ \sum_{k=1}^{t-p-1} \left\{ (y_{p+k} - W^T \Phi(y_{p+k})) (y_{p+k} - W^T \Phi(y_{p+k}))^T \right\}_{ji} - (t-p-1) \sigma_{ji} \right\}\end{aligned}$$

$$\frac{\partial L(\theta)}{\partial \sigma_{ij}} = 0 \text{ より}$$

$$\sigma_{ji} = \frac{1}{t-p-1} \sum_{k=1}^{t-p-1} \left((y_{p+k} - W^T \Phi(y_{p+k})) (y_{p+k} - W^T \Phi(y_{p+k}))^T \right)_{ji}$$

$$\Sigma_{ML} = \frac{1}{t-p-1} \sum_{k=1}^{t-p-1} (y_{p+k} - W^T \Phi(y_{p+k})) (y_{p+k} - W^T \Phi(y_{p+k}))^T$$

5 VARモデルの実装

In [1]:

```
module TSA

using Statistics
using PyCall
np = pyimport("numpy")

▼ mutable struct var
    p::Int
    params::Array{Float64}
    sig_matrix::Array{Float64}
end

▼ mutable struct ar
    p::Int
    params::Array{Float64}
    sig::Float64
end

# fit
▼ function fit!( model::var, data )

    nvar = size(data)[2]

    global design_matrix = zeros( size(data)[1]-model.p, nvar*model.p+1 )
    # 定数項
    design_matrix[:,1] .+= 1
    ▼ for i in 0 : model.p-1
        design_matrix[:, i*nvar+2 : i*nvar+nvar+1 ] += data[ model.p-i : end-1-i, : ]
    end

    data_matrix = data[ model.p+1 : end, : ]

    model.params = inv(design_matrix' design_matrix) design_matrix' data_matrix
    ▼ model.sig_matrix = (data_matrix' data_matrix
        - data_matrix' design_matrix*model.params
        - model.params' design_matrix' data_matrix
        + model.params' design_matrix' design_matrix*model.params )
        ./ ( length(data) - model.p*( nvar + 1 ) - 2 )

    return
end

▼ function fit!( model::ar, data )

    design_matrix = zeros( size(data)[1]-model.p, model.p+1 )
    # 定数項
    design_matrix[:,1] .+= 1
    ▼ for i in 0 : model.p-1
        design_matrix[:, i+2 ] += data[ model.p-i : end-1-i ]
    end

    data_matrix = data[ model.p+1 : end ]

    model.params = inv(design_matrix' design_matrix) design_matrix' data_matrix
    model.sig = mean( ( data_matrix .- (model.params' design_matrix') )' .^2 )

    return
end
```

```

# predict
function predict( model::var, data, ; length::Int=1 )
    nvar = size(data)[2]
    tmp_data = data

    for i in 1:length
        rev_data = reverse( tmp_data', dims=2 )

        basis_func = [1 ; rev_data[begin:model.p*nvar]]
        pre = model.params' basis_func
                + np.random.multivariate_normal(zeros(nvar), model.sig_matrix, size=1)'

        tmp_data = cat( tmp_data, pre', dims=1 )
    end

    return tmp_data
end

function predict( model::ar, data, ; length::Int=1 )

    tmp_data = data

    for i in 1:length
        rev_data = reverse( tmp_data )
        basis_func = [ 1; rev_data[begin:model.p] ]
        pre = model.params' basis_func + np.random.normal(0.0, np.sqrt( model.sig ) )
        push!( tmp_data, pre )
    end

    return tmp_data
end

# 区間推定
function interval_estimation( model::var, data, ; len::Int=1, iteration::Int=100 )

    resid = zeros( iteration, size(data)[2] )
    Ex = conditional_expectation( model, data, length_pre=len )
    for i in 1:iteration
        tmp = predict( model, data, length=len )[end,:] - Ex
        resid[i,:] = tmp'
        # 上記の書き方のほうがiterationが大きいとき早い
        # catを使うと10^6の時、三日たっても終わらなかった
        # resid = cat(resid, tmp', dims=1 )
        # resid = [ resid' tmp ]'
    end

    mse = mean( resid.^2, dims=1 )
    #return Ex
    # 95%区間予測
    return hcat(Ex - 1.96*np.sqrt( mse' ), Ex + 1.96*np.sqrt( mse' ))

end

function conditional_expectation( model::var, data, ; length_pre::Int=1 )
    nvar = size(data)[2]
    tmp_data = data

    for i in 1:length_pre
        rev_data = reverse( tmp_data', dims=2 )

        basis_func = [1 ; rev_data[begin:model.p*nvar] ]

```

```

pre = model.params.basis_func

tmp_data = cat( tmp_data, pre', dims=1 )
end

return tmp_data[end,:]

end
end;

```

6 行列の微分

$x^T \Sigma W^T y$ を w で微分

$$x = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} \quad y = \begin{bmatrix} y_1 \\ y_2 \\ y_3 \end{bmatrix} \quad W = \begin{bmatrix} w_{11} & w_{12} \\ w_{12} & w_{22} \\ w_{13} & w_{32} \end{bmatrix} \quad \Sigma = \begin{bmatrix} \sigma_{11} & \sigma_{12} \\ \sigma_{12} & \sigma_{22} \end{bmatrix}$$

$$(\Sigma W^T)_{ij} = \sum_k \Sigma_{ik} W_{kj}^T$$

$$x^T \Sigma W^T y = \sum_i \sum_j \sum_k \Sigma_{ik} W_{kj}^T x_i y_j$$

$$\frac{\partial}{\partial W_{sm}} = \sum_i \Sigma_{ik} W_{kj}^T x_i y_j$$

$$= \left(\sum_i x_{i1} \Sigma_{is} \right) y_m$$

$$= (x^T \Sigma)_s y_m$$

$$\frac{\partial x^T \Sigma W^T y}{\partial W} = y x^T \Sigma \quad (*)$$

$y^T W \Sigma W^T y$ を w で微分

$$(W\Sigma W^T)_{ij} = \sum_k \sum_l W_{ik} \Sigma_{kl} W_{lj}^T$$

$$y^T W \Sigma W^T y = \sum_i \sum_j \sum_k \sum_l W_{ik} \Sigma_{kl} W_{lj}^T y_i y_j$$

$$\frac{\partial}{\partial W_{sm}} = \sum_i \Sigma_{ik} W_{kj}^T x_i y_j$$

$$W_{sm} \text{で微分} \Rightarrow \begin{cases} \textcircled{1} & i = s, j = s, k = m, l = m & \Rightarrow & 2W_{sm} y_s^2 \Sigma_{mm} \\ \textcircled{2} & i = s, j \neq s, k = m, l \neq m & \Rightarrow & \sum_{j \neq s} \sum_{l \neq m} W_{jl} \Sigma_{sl} y_s y_j \\ \textcircled{3} & i \neq s, j = s, k \neq m, l = m & \Rightarrow & \sum_{i \neq s} \sum_{k \neq m} W_{ik} \Sigma_{km} y_i y_s \end{cases}$$

$\Sigma = \Sigma^T$ であることから、 $\textcircled{2} = \textcircled{3}$

$$\textcircled{1} + \textcircled{2} + \textcircled{3} = 2 \left(W_{sm} y_s^2 \Sigma_{mm} + \sum_{j \neq s} \sum_{l \neq m} W_{jl} \Sigma_{sl} y_s y_j \right)$$

$$= 2 \left(\sum_j \sum_l W_{jl} \Sigma_{ml} y_s y_j \right)$$

$$= 2 \left(\sum_j \left(\sum_l W_{jl} \Sigma_{ml} \right) y_s y_j \right)$$

$$= 2 \left(\sum_j (W\Sigma)_{jm} y_s y_j \right)$$

$$= 2 \left(\left(\sum_j y_{j1} (W\Sigma)_{jm} \right) y_s \right)$$

$$= 2 (y^T W \Sigma)_m y_s$$

$$= 2 (y y^T W \Sigma)_{sm}$$

$$\frac{\partial y^T W \Sigma W^T y}{\partial W} = y y^T W \Sigma$$

(*)